GSLC

Abraham Gregorius Anderson Thio (2802473504)

1. Efek Regularisasi pada Batch Normalization (Slide 6–8)

a. Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi.

Batch Normalization (BN) menggunakan mean dan variance dari mini-batch untuk menormalisasi aktivasi. Karena setiap mini-batch memiliki komposisi berbeda, estimasi statistiknya juga bervariasi. Variasi ini menimbulkan noise stokastik pada aktivasi yang bertindak sebagai regularisasi implisit, sehingga membantu mengurangi overfitting dan meningkatkan generalisasi.

b. Uraikan kondisi ketika menghilangkan Dropout tidak lagi berlaku atau dapat memicu instabilitas pelatihan.

Dropout masih dapat diperlukan ketika dataset kecil, model memiliki kapasitas besar, atau overfitting tetap terjadi. Selain itu, mini-batch yang terlalu kecil dapat menghasilkan estimasi mean dan variance yang tidak stabil, sehingga mengganggu pelatihan. Perbedaan distribusi data pelatihan dan pengujian juga dapat mengurangi efektivitas BN.

2. Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)

a. Mengapa penambahan lapisan pada plain CNN justru dapat menurunkan akurasi pelatihan meskipun secara teoritis dapat menyamai model dangkal melalui identity mapping?

Penambahan lapisan meningkatkan kompleksitas optimisasi. Gradien dapat mengalami vanishing gradient, sementara optimisasi menjadi lebih sulit menemukan parameter yang menghasilkan identity mapping. Akibatnya, model

yang lebih dalam dapat memiliki akurasi pelatihan lebih rendah meskipun kapasitas representasinya lebih besar. Fenomena ini disebut *degradation problem*.

b. Bagaimana skip connection mengubah formulasi aliran gradien saat backpropagation?

Skip connection menggunakan formulasi residual:

$$H(x) = F(x) + xH(x) = F(x) + x$$

Gradien mengalir melalui jalur transformasi F(x)F(x) dan jalur identitas xx. Secara matematis:

$$\partial L \partial x = \partial L \partial H (\partial F \partial x + I) \frac{\partial L}{\partial x} = \frac{\partial L}{\partial H} \left(\frac{\partial F}{\partial x} + I \right)$$

Komponen identitas II menyediakan jalur langsung bagi gradien tanpa harus melewati seluruh transformasi lapisan.

c. Hubungkan mekanisme tersebut dengan mitigasi vanishing gradient.

Jalur identitas membantu gradien mencapai lapisan awal tanpa mengalami pelemahan berulang akibat perkalian turunan dari banyak lapisan. Dengan demikian, skip connection mempermudah pelatihan jaringan yang dalam, meskipun tidak sepenuhnya menghilangkan risiko vanishing gradient.

3. Feature Extraction vs. Fine-Tuning (Slide 14–16)

a. Bandingkan jumlah trainable parameters.

Feature Extraction membekukan backbone sehingga hanya parameter classifier yang diperbarui. Fine-Tuning membuka sebagian atau seluruh backbone sehingga jumlah parameter yang diperbarui lebih banyak.

b. Bandingkan kebutuhan volume data latih.

Feature Extraction cocok untuk dataset kecil karena memanfaatkan fitur bawaan model. Fine-Tuning umumnya membutuhkan data lebih banyak agar penyesuaian parameter tidak menyebabkan overfitting.

c. Bandingkan beban komputasi dan memori per epoch.

Feature Extraction lebih hemat komputasi dan memori karena gradien tidak perlu dihitung untuk backbone yang dibekukan. Fine-Tuning membutuhkan lebih banyak sumber daya karena gradien dihitung dan parameter diperbarui pada lapisan yang dibuka.

d. Bandingkan risiko destructive gradient updates.

Feature Extraction memiliki risiko rendah karena representasi backbone tidak berubah. Fine-Tuning memiliki risiko lebih tinggi karena pembaruan parameter yang terlalu besar dapat merusak fitur yang telah dipelajari saat pretraining.

e. Sintesis kriteria praktis pemilihan pendekatan.

Feature Extraction tepat untuk dataset kecil, sumber daya terbatas, dan domain yang mirip dengan data prapelatihan. Fine-Tuning lebih tepat jika tersedia data yang memadai atau domain target berbeda secara signifikan. Kombinasi keduanya dapat digunakan dengan memulai dari Feature Extraction, kemudian membuka sebagian lapisan dengan learning rate kecil.

4. Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)

a. Mengapa augmentation hanya diterapkan pada train set?

Augmentation memperkaya variasi data pelatihan sehingga model lebih robust dan tidak mudah overfitting. Validation dan test set harus menggunakan transformasi yang konsisten agar evaluasi objektif, dapat dibandingkan, dan merepresentasikan performa pada data sebenarnya.

b. Berikan contoh transformasi yang tidak layak untuk klasifikasi pet breeds dan jelaskan berdasarkan invariansi semantik label.

Rotasi ekstrem hingga 180 derajat dapat membuat citra hewan tidak representatif atau menyulitkan identifikasi ciri ras. Transformasi tersebut berisiko menghilangkan informasi visual penting, seperti bentuk telinga dan proporsi tubuh.

Berdasarkan prinsip *invariansi semantik label*, augmentasi harus mengubah tampilan citra tanpa mengubah identitas kelas atau menghilangkan ciri penting

yang diperlukan untuk membedakan ras.

5. Mitigasi Catastrophic Forgetting (Slide 28–29)

a. Bagaimana catastrophic forgetting terjadi?

Catastrophic forgetting terjadi ketika fine-tuning mengubah parameter model secara berlebihan sehingga representasi yang telah dipelajari selama pretraining ikut rusak. Akibatnya, model kehilangan sebagian fitur bawaan dan dapat mengalami penurunan kemampuan generalisasi.

b. Jelaskan dua strategi mitigasi beserta alasan teoritisnya.

1. **Differential learning rate:** Menggunakan learning rate kecil pada backbone dan lebih besar pada classifier. Strategi ini membatasi perubahan fitur bawaan sekaligus memungkinkan classifier baru beradaptasi lebih cepat terhadap data target.
2. **Gradual unfreezing:** Membuka lapisan secara bertahap, dimulai dari classifier kemudian lapisan backbone yang lebih dalam. Strategi ini mengurangi perubahan parameter secara mendadak dan membantu mempertahankan representasi hasil pretraining.